

Bilan Mensuel — Fondations Data

Python · Pandas · Matplotlib · Seaborn · PostgreSQL · DBeaver

4 semaines · 3 datasets · Exploration → Nettoyage → Analyse → SQL

1. Évolution globale

D'où tu partais

Python connu mais orienté développement (Angular, scripts hedge fund) — pas data. Aucune pratique de Pandas, aucune notion de SQL appliqué à l'analyse, aucune habitude de travailler sur des datasets réels avec une logique d'exploration structurée. La reconversion data était un objectif clair mais sans fondation technique spécifique au métier.

Ce que tu comprends maintenant

- Un dataset n'est pas juste un fichier — chaque ligne représente quelque chose de précis, et lire cette signification est le premier réflexe d'un analyste.
- Le nettoyage n'est pas une étape mécanique — chaque décision dépend du sens de la donnée, pas du volume de NaN ou du pourcentage de doublons.
- L'analyse commence par une question, pas par du code. Sans question, les chiffres ne racontent rien.
- Pandas et SQL répondent aux mêmes questions — la logique mentale est identique, seule la syntaxe change.
- La visualisation est une traduction, pas une répétition — elle illustre ce que l'agrégation a déjà révélé.

Ce qui a changé dans ta manière de réfléchir

La transformation mentale clé

Avant : écrire du code pour voir ce qui sort.

Maintenant : formuler une question, choisir l'outil qui y répond, interpréter le résultat.

Ce changement est la différence entre un développeur qui fait de la data et un data analyst. Il ne s'acquiert pas en lisant — il vient de l'avoir pratiqué sur 3 datasets réels avec des erreurs, des corrections et des réinterprétations.

Exemple concret : semaine 3, tu as identifié que le classement par volume et le classement par CA ne coïncident pas sur Coffee Sales. Ce n'est pas une observation technique — c'est un raisonnement métier.

2. Compétences acquises

Technique

Domaine	Compétences maîtrisées
Pandas — Exploration	pd.read_csv, head(), info(), describe(), shape, dtypes, isnull().sum(), unique(), value_counts()
Pandas — Nettoyage	fillna(), dropna(), drop_duplicates(), drop(), astype(), to_datetime(), to_csv()
Pandas — Analyse	groupby() + agg(), sort_values(), nlargest(), .dt.month / .dt.year / .dt.day_name(), reset_index()
Visualisation	Matplotlib : bar chart, line chart — Seaborn : histogramme, boxplot, scatter plot — savefig(), tight_layout()
SQL	SELECT, DISTINCT, WHERE, BETWEEN, ORDER BY, LIMIT, GROUP BY, SUM / COUNT / AVG / ROUND, HAVING, EXTRACT, TO_CHAR, JOIN
Environnement	Jupyter, Anaconda, GitHub Desktop, DBeaver, PostgreSQL — structure repo cohérente

Méthodologie

Compétence	Ce que ça signifie concrètement
Diagnostic dataset	Lire describe() + info() + isnull().sum() avant toute action — comprendre la forme avant le fond
Prise de décision	Choisir fillna vs dropna vs drop() selon le sens métier, pas selon le volume — documenter le choix
Ordre des opérations	Supprimer les colonnes inutiles AVANT les doublons. Nettoyer AVANT d'analyser. Question AVANT le code.
Documentation	Format 3 questions systématique : Ce que j'ai fait / Pourquoi / Ce que ça m'a appris
Structuration repo	Dossiers séparés datasets / notebooks / sql / visuals / notes — README à jour — commits réguliers
Décisions différées	Identifier et documenter ce qui est hors scope (genre_ids TMDB) sans le laisser comme oublié

3. Ce que tu sais faire concrètement

C'est cette section qui compte le plus pour un recruteur ou un jury de projet.

Elle décrit ce que tu peux livrer — pas ce que tu as étudié.

Nettoyer un dataset complet de A à Z

- Charger un CSV avec les bons paramètres (séparateur, encodage)
- Diagnostiquer les NaN, identifier leur cause métier, choisir la stratégie adaptée
- Détecter les vrais doublons en neutralisant les colonnes d'index parasites
- Corriger les types (datetime, numérique) et extraire les composantes temporelles
- Supprimer les colonnes sans valeur analytique
- Exporter un dataset propre et documenter chaque décision

Analyser un dataset et extraire des insights

- Calculer CA, volume, prix moyen par catégorie avec groupby()
- Identifier les top N sur n'importe quelle métrique avec nlargest()
- Analyser des tendances temporelles (par mois, par jour de la semaine)
- Distinguer ce que describe() dit du dataset vs ce que groupby() révèle sur la donnée
- Formuler un contre-intuitif et l'étayer : volume $\neq$ valeur, fréquence $\neq$ poids

Produire des visualisations pertinentes

- Choisir le type de graphique en fonction de la question posée, pas d'un choix esthétique
- Construire les 5 types fondamentaux : bar chart, line chart, histogramme, boxplot, scatter plot
- Lire et interpréter un boxplot (Q1, Q3, médiane, outliers) et un histogramme multimodal
- Exporter les visuels en .png dans un dossier dédié

Reproduire une analyse en SQL

- Créer une base PostgreSQL, déclarer les tables, importer des CSV nettoyés
- Interroger, filtrer et trier avec SELECT / WHERE / ORDER BY / LIMIT
- Reproduire des groupby() Pandas en SQL avec GROUP BY et les agrégats correspondants
- Filtrer sur des agrégats avec HAVING
- Extraire des composantes temporelles avec EXTRACT et TO_CHAR
- Créer et interroger une jointure entre deux tables
- Organiser et versionner les scripts SQL dans un repo GitHub structuré

4. Points encore fragiles

SQL — à consolider

- Automatisation SQL : la syntaxe est comprise mais pas encore réflexe
- Ordre d'exécution SQL mémorisé intellectuellement, pas encore instinctif
- Guillemets doubles sur colonnes avec espaces — oubli possible sous pression
- HAVING vs WHERE : le piège est connu, pas encore évité automatiquement

Pandas / Visualisation — à fluidifier

- Logique d'analyse en construction : formuler la bonne question avant le code
- `reset_index()` après `groupby()` — réflexe pas encore systématique
- Syntaxe Matplotlib/Seaborn : l'ordre des 7 étapes pas encore automatique
- Lecture de graphiques complexes (multimodal, outliers extrêmes) encore hésitante

Ce qui va résoudre ces points

Pas de révision théorique supplémentaire — de la pratique répétée sur de vrais projets.

Le mois 2 (projet e-commerce complet) imposera d'écrire des dizaines de requêtes et d'agrégations.

Les erreurs faites et corrigées en conditions de projet construisent l'automatisme — pas les exercices guidés.

5. Leçons majeures du mois

1

Le nettoyage dépend du sens de la donnée, pas du volume.

2.4% de NaN sur Coffee Sales → `fillna()`. 0.01% sur TMDB → `drop()`. La décision n'est jamais mécanique. Chaque dataset, chaque colonne, chaque contexte métier impose une stratégie différente.

2

Volume ≠ valeur — toujours croiser les deux lectures.

Americano with Milk est le café le plus vendu. Le Latte est le plus rentable. Saint-Lazare apparaît le plus souvent dans le dataset. Gare du Nord concentre le plus de voyageurs. Un chiffre seul est toujours incomplet.

3

L'ordre des opérations n'est pas anodin.

Unnamed:0 masquait 8820 vrais doublons sur TMDB. Sans supprimer la colonne d'index AVANT de chercher les doublons, `duplicated().sum()` affichait 0. L'ordre : colonnes inutiles → doublons → types → analyse.

4

L'analyse commence par une question, pas par du code.

`describe()` dit comment le dataset est construit. `groupby()` dit ce que la donnée raconte. Sans question préalable, les agrégations produisent des chiffres sans signification. Ce réflexe se construit — il n'est pas encore automatique.

Documenter une décision différée n'est pas un oubli.

`genre_ids` laissée en objet intentionnellement — `ast.literal_eval()` + `explode()` hors scope mois 1. Le noter explicitement dans le bilan est une pratique professionnelle : ça distingue un oubli d'un choix éclairé.

6. Ce qui a le mieux fonctionné

Approche	Pourquoi ça a fonctionné
Structure semaine par semaine	Chaque semaine avait un objectif clair et délimité. Pas de surcharge, progression visible, satisfaction à chaque boucle fermée.
3 datasets en parallèle	Chaque dataset avait ses propres problèmes — ça a forcé à généraliser les réflexes plutôt que mémoriser une recette.
Format 3 questions	Ce que j'ai fait / Pourquoi / Ce que ça m'a appris — force à articuler la logique, pas juste à exécuter.
Claude comme outil d'apprentissage	Explication des concepts avant implémentation, correction immédiate, adaptation au niveau réel — plus efficace que des tutoriels génériques.
GitHub dès le début	Chaque semaine committée = trace de progression visible, habitude professionnelle acquise naturellement.
Bilans documentés (.docx)	Mettre des mots sur ce qu'on a appris consolide la compréhension et produit une trace réutilisable.

7. Ce que tu changes pour le Mois 2

Moins de guidé, plus de projet réel

- Partir d'une problématique métier choisie dès le début — pas d'exercices découpés
- Formuler les questions d'analyse avant d'ouvrir Jupyter
- Construire une vraie narration autour des insights, pas juste des sorties de code

Plus d'interprétation, moins de technique pure

- Chaque agrégation doit répondre à une question explicitement posée
- Chaque graphique doit avoir une légende et une interprétation dans le notebook
- Les insights doivent être formulés comme un analyste les présenterait — pas comme un commentaire de code

SQL intégré au projet, pas en exercice séparé

- Utiliser SQL et Pandas sur le même dataset dans le même projet

- Comparer les résultats des deux outils — vérifier la cohérence
- Commencer à utiliser des CTEs et des sous-requêtes dès que le besoin apparaît

Candidatures en parallèle

- 5 à 10 candidatures ciblées par semaine à partir du mois 2
- LinkedIn mis à jour progressivement au fil des projets complétés
- Chaque projet terminé = élément de portfolio ajouté au profil

8. Objectif Mois 2

Objectif principal

Réaliser un projet Data Analyst complet sur un dataset e-commerce :
problématique choisie → exploration → nettoyage → analyse → visualisation → storytelling
→ SQL.

Le livrable n'est pas un notebook rempli d'exercices — c'est une analyse avec un fil conducteur,
des insights actionnables, et une présentation qui pourrait être montrée à un recruteur.

Dimension	Objectif concret
Technique	Maîtriser groupby() complexes, jointures SQL réelles, premières CTEs
Analyse	Formuler 3-5 questions métier et y répondre avec données à l'appui
Visualisation	Dashboard ou rapport visuel cohérent — pas des graphiques isolés
SQL	Reproduire l'analyse complète en SQL — consolider les réflexes WHERE/HAVING
Portfolio	Repo GitHub propre avec README orienté recruteur
Candidatures	5-10 par semaine — APEC, WTTJ, Indeed — Data Analyst junior

Mois 1 — Fondations posées.

Python maîtrisé. Pandas opérationnel. SQL acquis. Méthode installée. Le mois 2 commence.