

Mois 1 — Fondations Data

Bilan Semaine 3 — Analyse et visualisation

Outils : Python · Pandas · Matplotlib · Seaborn · Jupyter

Bilan général

Ressenti global : Syntaxes peu intuitives, semaine techniquement dense.

Leçon fondamentale de la semaine :

La logique d'analyse reste encore floue — et c'est normal à ce stade. L'exploration et le nettoyage ont des objectifs évidents et balisés. L'analyse demande de formuler une question avant d'écrire du code. Ce réflexe ne s'acquiert pas en une semaine — il viendra avec les projets du mois 2 où les problématiques seront choisies dès le départ.

Ce qui a été fait

6 exercices couvrant les 3 datasets :

- Exercice 1 : agrégations groupby() sur Coffee Sales (CA, nombre de ventes, prix moyen)
- Exercice 2 : analyse temporelle par mois et jour de la semaine
- Exercice 3 : top 5 et filtrage sur Coffee Sales et Transilien
- Exercice 4 : bar chart et line chart avec Matplotlib
- Exercice 5 : histogramme et boxplot avec Seaborn
- Exercice 6 : distribution, évolution et scatter plot sur TMDB

Graphiques exportés dans visuals/ :

- ca_par_produit.png · ca_par_mois.png · distribution_prix_des_cafés.png
- frequentation_type_jour.png · distribution_notes.png · films_par_annee.png · popularité_vs_moyenne.png

Insights retenus par dataset

Coffee Sales

- Le classement par volume et le classement par CA ne coïncident pas.
- Americano with Milk est le plus vendu (824 ventes) mais le Latte domine le CA (27 866€) grâce à son prix moyen plus élevé (35,63€ contre 30,67€).
- Contre-intuition : les cafés les plus chers sont aussi les plus consommés en valeur.
- Mars est le meilleur mois (17 036€). Clientèle majoritairement de semaine — dimanche = jour le plus faible (434 ventes).

Transilien

- Trafic très concentré : Paris-Gare-du-Nord domine avec 747 021 voyageurs — plus du double de Saint-Lazare (310 848).
- Contre-intuition : Saint-Lazare avait le plus d'apparitions dans `describe()` mais Gare du Nord concentre le plus de voyageurs. Fréquence d'apparition $\neq$ valeur agrégée.
- Le boxplot confirme visuellement le CV de 279% de la semaine 1 : quelques tranches d'heures de pointe concentrent l'essentiel du trafic, encore plus marqué en JOB (outliers à 47 000 voyageurs).

TMDB

- `nlargest()` sur `vote_average` seul est insuffisant : *Cuando Sea Joven* est premier (8,8) avec 202 votes contre 23 302 pour *The Shawshank Redemption* — biais à identifier avant toute conclusion.
- Popularité et note sont deux métriques indépendantes : aucune corrélation linéaire visible sur le scatter plot.
- La production cinématographique explose à partir des années 1990 avec un pic en 2019 (403 films).

Points encore fragiles

`reset_index()`

Nécessaire après `groupby()` pour que la colonne de regroupement redevienne une colonne ordinaire. Sans `reset_index()`, la colonne est un index et `plt.plot()` ne peut pas y accéder.

`idxmax()` + `loc[]` imbriqués

Logique à lire de l'intérieur vers l'extérieur : `idxmax()` trouve la position de la valeur max, puis `loc[]` récupère la ligne à cette position. Décomposer en deux étapes séparées aide à la compréhension.

Syntaxe Matplotlib/Seaborn

Pas encore intuitive. Ordre des 7 étapes à consolider :

- `figsize` $\rightarrow$ `tracer` $\rightarrow$ `titre/labels` $\rightarrow$ `xticks` $\rightarrow$ `tight_layout` $\rightarrow$ `savefig` $\rightarrow$ `show()`

Règle clé : le type de graphique découle de la question posée, pas d'un choix esthétique.

Question posée	Graphique
Comparer des catégories	Bar chart
Évolution dans le temps	Line chart
Répartition d'une variable numérique	Histogramme
Dispersion entre groupes	Boxplot
Relation entre deux variables numériques	Scatter plot

Lecture et interprétation des graphiques

- Histogramme : l'axe Y est la fréquence — le nombre de lignes dans chaque tranche de valeurs.
- Boxplot : la boîte = 50% des données (Q1 à Q3), la ligne centrale = médiane, les points = outliers.
- Distribution multimodale = plusieurs pics distincts, pas une seule valeur dominante.

Leçons transversales

1. Volume ≠ valeur

Americano with Milk plus vendu, Latte plus rentable. Saint-Lazare plus présent dans le dataset, Gare du Nord plus fréquentée. Toujours croiser les deux lectures.

2. describe() et groupby() répondent à des questions différentes

describe() dit comment le dataset est construit. groupby() dit ce que la donnée raconte. Les deux sont nécessaires, dans cet ordre.

3. La visualisation illustre, elle n'interprète pas une deuxième fois

L'interprétation se fait dans la cellule Markdown après l'agrégation. Le graphique en est la traduction visuelle — pas un doublon.

4. Pandas et SQL partagent la même logique mentale

Pandas	SQL
groupby('col')	GROUP BY col
.sum() / .mean() / .count()	SUM() / AVG() / COUNT()
sort_values()	ORDER BY
df[df['col'] == 'x']	WHERE col = 'x'
.nlargest(5)	ORDER BY ... DESC LIMIT 5

La syntaxe Pandas deviendra plus claire après la semaine 4 SQL — chaque commande aura son équivalent direct.

Semaine 4 — SQL et retransposition

SELECT · WHERE · GROUP BY · ORDER BY · JOIN · PostgreSQL

Retransposer en SQL les analyses faites en Pandas cette semaine. Les mêmes questions, les mêmes résultats, une syntaxe différente.